Texto como datos

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

1. ¿Por qué texto?
2. ¿Qué ve el econometrista?
3. ¿Qué tokens descartamos?
4. ¿Cómo pesamos las palabras?
5. Ejemplo: Gentzkow y Shapiro

Texto como datos

Intro

- El texto es una fuente enorme de datos: noticias, informes, discursos, contratos, reseñas, redes sociales.
- Viene conectado a variables de su "autor" que nos interesan:
  - qué compramos, qué vemos, qué opinamos,
  - a qué grupo pertenecemos, a quién representamos,
  - cómo se mueven los mercados y la macroeconomía.

Texto como datos

Intro

- El texto es una fuente enorme de datos: noticias, informes, discursos, contratos, reseñas, redes sociales.
- Viene conectado a variables de su "autor" que nos interesan:
  - qué compramos, qué vemos, qué opinamos,
  - a qué grupo pertenecemos, a quién representamos,
  - cómo se mueven los mercados y la macroeconomía.
- El problema: el texto no viene en filas y columnas.
- ¿Cómo lo convertimos en una matriz X que podamos usar con lo que ya sabemos?

Texto como datos

Motivación: sentimiento de los medios y el mercado

THE JOURNAL OF FINANCE • VOL. LXII, NO. 3 • JUNE 2007

Giving Content to Investor Sentiment: The Role of Media in the Stock Market

PAUL C. TETLOCK*

ABSTRACT

I quantitatively measure the interactions between the media and the stock market using daily content from a popular *Wall Street Journal* column. I find that high media pessimism predicts downward pressure on market prices followed by a reversion to fundamentals, and unusually high or low pessimism predicts high market trading volume. These and similar results are consistent with theoretical models of noise and liquidity traders, and are inconsistent with theories of media content as a proxy for new information about fundamental asset values, as a proxy for market volatility, or as a sideshow with no relationship to asset markets.

Texto como datos

Motivación: ¿qué determina el sesgo de los medios?

Econometrica, Vol. 78, No. 1 (January, 2010), 35–71

WHAT DRIVES MEDIA SLANT? EVIDENCE FROM U.S. DAILY NEWSPAPERS

BY MATTHEW GENTZKOW AND JESSE M. SHAPIRO[1]

We construct a new index of media slant that measures the similarity of a news outlet's language to that of a congressional Republican or Democrat. We estimate a model of newspaper demand that incorporates slant explicitly, estimate the slant that would be chosen if newspapers independently maximized their own profits, and compare these profit-maximizing points with firms' actual choices. We find that readers have an economically significant preference for like-minded news. Firms respond strongly to consumer preferences, which account for roughly 20 percent of the variation in measured slant in our sample. By contrast, the identity of a newspaper's owner explains far less of the variation in slant.

KEYWORDS: Bias, text categorization, media ownership.

- Para responderla necesitan medir el sesgo: ¿qué tan "republicano" habla un periódico?

Agenda

1. ¿Por qué texto?
2. ¿Qué ve el econometrista?
3. ¿Qué tokens descartamos?
4. ¿Cómo pesamos las palabras?
5. Ejemplo: Gentzkow y Shapiro

La unidad de análisis

- Un pasaje de *Como gustéis*, de Shakespeare:

  All the world's a stage, and all the men and women merely players: they have their exits and their entrances; and one man in his time plays many parts...

La unidad de análisis

- Un pasaje de *Como gustéis*, de Shakespeare:

  All the world's a stage, and all the men and women merely players: they have their exits and their entrances; and one man in his time plays many parts...

- Lo que ve el econometrista:

world	stage	men	women	play	exit	entrance	time
1	1	2	1	2	1	1	1

Bag of words (BOW)

- **Tokenizar** = partir el texto en unidades (*tokens*), por ejemplo, palabras:

```
"La economía crece rápido" → [la, economía, crece, rápido]
```

- Luego ignoramos gramática y orden: cada documento es un vector de frecuencia sobre un vocabulario de V palabras,

$$d = (c_1, c_2, \ldots, c_V)$$

Bag of words (BOW)

- **Tokenizar** = partir el texto en unidades (*tokens*), por ejemplo, palabras:

```
"La economía crece rápido" → [la, economía, crece, rápido]
```

- Luego ignoramos gramática y orden: cada documento es un vector de frecuencia sobre un vocabulario de V palabras,

$$d = (c_1, c_2, \ldots, c_V)$$

- ¿Por qué funciona? **Hipótesis distribucional** (Harris, 1954): documentos con distribuciones de palabras parecidas hablan de temas parecidos.

Bag of words (BOW)

Ejemplo

- A: *Given the current outlook for inflation and economic growth, the central bank should reduce interest rates. Lower rates would support investment, employment, and economic activity without creating significant inflationary pressures.*

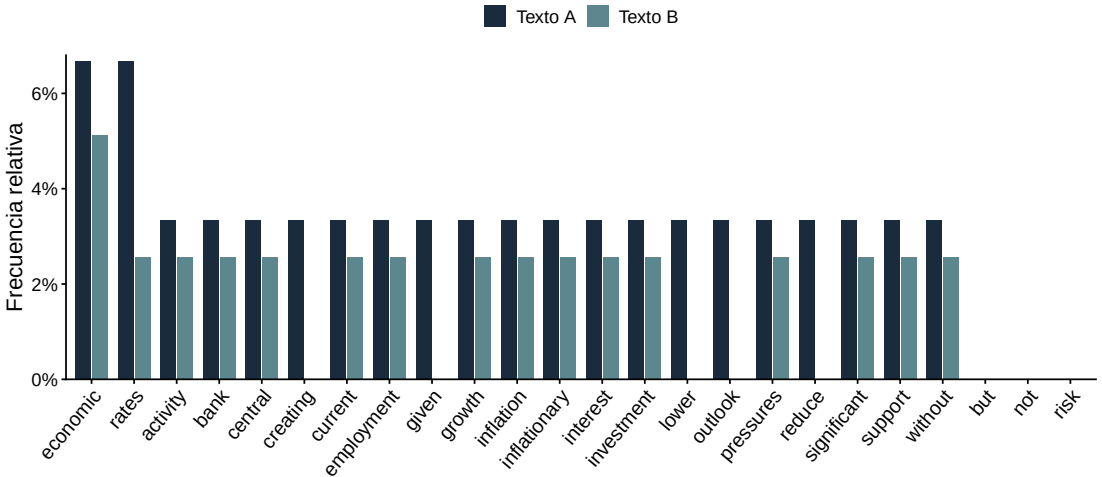
Bag of words (BOW)

Ejemplo

- A: *Given the current outlook for inflation and economic growth, the central bank should reduce interest rates. Lower rates would support investment, employment, and economic activity without creating significant inflationary pressures.*
- B: *Inflationary pressures have moderated, while economic growth and employment remain weak. A reduction in interest rates would stimulate investment and support economic activity. Under current conditions, the central bank has room to ease monetary policy without generating significant inflation.*

Bag of words (BOW)

¿Qué tan parecidos son?



Bag of words (BOW)

¿Qué tan parecidos son?

- A: *Given the current outlook for inflation and economic growth, the central bank should reduce interest rates. Lower rates would support investment, employment, and economic activity without creating significant inflationary pressures.*
- C: *Given the current outlook for inflation and economic growth, the central bank should not reduce interest rates. Lower rates would support investment, employment, and economic activity, but risk creating significant inflationary pressures.*

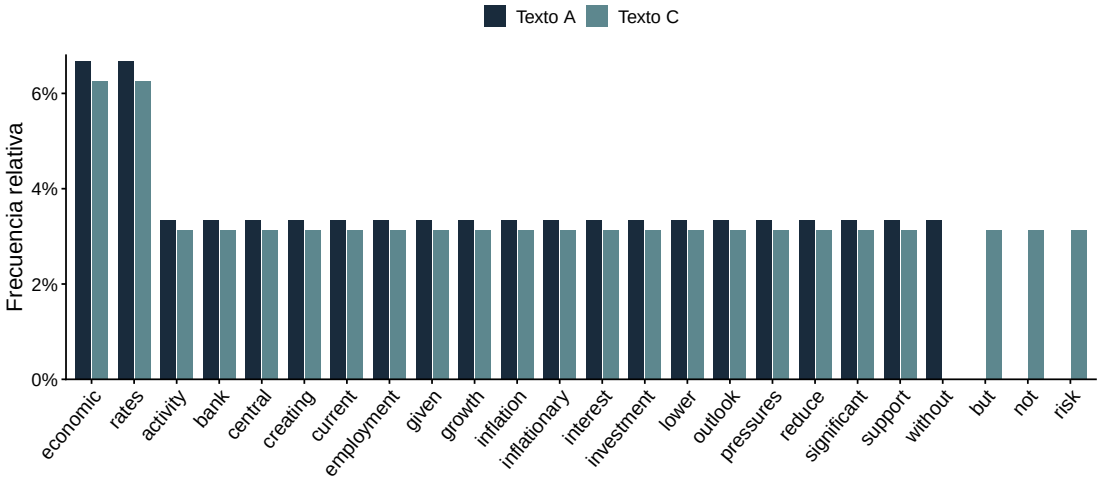
Bag of words (BOW)

¿Qué tan parecidos son?

- A: *Given the current outlook for inflation and economic growth, the central bank should reduce interest rates. Lower rates would support investment, employment, and economic activity without creating significant inflationary pressures.*
- C: *Given the current outlook for inflation and economic growth, the central bank should not reduce interest rates. Lower rates would support investment, employment, and economic activity, but risk creating significant inflationary pressures.*

Bag of words (BOW)

¿Qué tan parecidos son?



Del documento al corpus

- **Documento**: un texto (un artículo, un tuit, un discurso, un resumen).
- **Corpus**: una colección de documentos.
  - Todas las obras de Shakespeare.
  - Los comunicados del Banco de la República.
  - Los discursos del Congreso

La matriz documento-término (DTM)

- Aplicamos la bolsa de palabras a cada documento y apilamos:

$$X = \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1V} \\ c_{21} & c_{22} & \dots & c_{2V} \\ \vdots & \vdots & \ddots & \vdots \\ c_{D1} & c_{D2} & \dots & c_{DV} \end{bmatrix}$$

- Filas: documentos (D). Columnas: términos (V). Celda c_{ij}: cuántas veces aparece el término j en el documento i.

La matriz documento-término (DTM)

Un ejemplo

D1. La inflación sube.

D2. La inflación baja y el empleo sube.

D3. El empleo baja.

Otra forma de guardar lo mismo

El formato *tidy*: un token por fila

DTM (ancha)

	inflación	sube	empleo
D1	1	1	0
D2	1	1	1
D3	0	0	1

Tidy (larga)

doc	palabra	n
D1	inflación	1
D1	sube	1
D2	inflación	1
D2	sube	1
D2	empleo	1
D3	empleo	1

Agenda

1. ¿Por qué texto?
2. ¿Qué ve el econometrista?
3. ¿Qué tokens descartamos?
4. ¿Cómo pesamos las palabras?
5. Ejemplo: Gentzkow y Shapiro

Limpieza

- No todas las palabras le aportan a la DTM. No hay receta única: depende del objetivo y de la fuente.
- Pasos comunes:
  - minúsculas, sin números ni puntuación
    ojo: en tuits, `:-)` es información
  - quitar **palabras vacías** (*stop words*): de, la, que, el, en, y…
  - quitar palabras muy raras

Limpieza

- No todas las palabras le aportan a la DTM. No hay receta única: depende del objetivo y de la fuente.
- Pasos comunes:
  - minúsculas, sin números ni puntuación
    ojo: en tuits, :-) es información
  - quitar **palabras vacías** (*stop words*): de, la, que, el, en, y…
  - quitar palabras muy raras
- Cada corpus tiene además sus propias palabras vacías: en el Congreso, *mr speaker*, *yield*, *gentleman*; en un banco central, *junta*, *directiva*.
- La palabra vacía de uno es la palabra clave de otro

Llevar las palabras a su forma base

- Objetivo: que *económico, económica, económicas* cuenten como una sola.
- **Stemming** (raíz): reglas que cortan terminaciones. Rápido, pero burdo.
- **Lematización** (lema): diccionario + gramática. Preciso, pero más lento.

Palabras	Raíz (Snowball)	Lema
niño, niña, niños, niñas	niñ	niño
económico, económica, economía	econom	económico / economía
crecer, creció	crec	crecer
política, políticas, políticos	polit	político / política

- Velocidad vs. precisión.

N-gramas: recuperar algo de orden

- Un **n-grama** es una secuencia de n palabras consecutivas.
  - Unigramas: *tax*, *deuda*
  - Bigramas: *death tax*, *estate tax*, *deuda externa*
  - Trigramas: *inversión extranjera directa*
- Capturan contexto local: *tax* no dice nada del partido; *death tax* y *estate tax* sí (es el mismo impuesto a la herencia).

N-gramas: recuperar algo de orden

- Un **n-grama** es una secuencia de n palabras consecutivas.
  - Unigramas: *tax*, *deuda*
  - Bigramas: *death tax*, *estate tax*, *deuda externa*
  - Trigramas: *inversión extranjera directa*
- Capturan contexto local: *tax* no dice nada del partido; *death tax* y *estate tax* sí (es el mismo impuesto a la herencia).
- Costo: el vocabulario crece muy rápido (hasta V^n combinaciones) y casi todas son raras $\Rightarrow$ más ceros.

Agenda

1. ¿Por qué texto?
2. ¿Qué ve el econometrista?
3. ¿Qué tokens descartamos?
4. ¿Cómo pesamos las palabras?
5. Ejemplo: Gentzkow y Shapiro

TF-IDF

- Las palabras más frecuentes aparecen en todos los documentos: no distinguen a ninguno. Queremos las frecuentes *en este* documento y raras *en el resto*.

TF-IDF

- Las palabras más frecuentes aparecen en todos los documentos: no distinguen a ninguno. Queremos las frecuentes *en este* documento y raras *en el resto*.
- **Frecuencia del término** en el documento d y **frecuencia inversa en documentos**:

$$\text{tf}(t,d) = \frac{c_{td}}{\sum_{t'} c_{t'd}} \qquad \text{idf}(t) = \ln\left(\frac{D}{\#\{d : c_{td} > 0\}}\right)$$

- **TF-IDF** $= \text{tf}(t,d) \times \text{idf}(t)$.
- Si t aparece en todos los documentos: idf $= \ln 1 = 0$.

Agenda

1. ¿Por qué texto?
2. ¿Qué ve el econometrista?
3. ¿Qué tokens descartamos?
4. ¿Cómo pesamos las palabras?
5. Ejemplo: Gentzkow y Shapiro

Econometrica, Vol. 78, No. 1 (January, 2010), 35–71

WHAT DRIVES MEDIA SLANT? EVIDENCE FROM U.S. DAILY NEWSPAPERS

BY MATTHEW GENTZKOW AND JESSE M. SHAPIRO[1]

We construct a new index of media slant that measures the similarity of a news outlet's language to that of a congressional Republican or Democrat. We estimate a model of newspaper demand that incorporates slant explicitly, estimate the slant that would be chosen if newspapers independently maximized their own profits, and compare these profit-maximizing points with firms' actual choices. We find that readers have an economically significant preference for like-minded news. Firms respond strongly to consumer preferences, which account for roughly 20 percent of the variation in measured slant in our sample. By contrast, the identity of a newspaper's owner explains far less of the variation in slant.

KEYWORDS: Bias, text categorization, media ownership.

- Para responderla necesitan medir el sesgo: ¿qué tan "republicano" habla un periódico?

Gentzkow y Shapiro (2010)

Las palabras predicen el voto?

- Todos los discursos del 109.º Congreso de EE. UU. en 2005 (Cámara y Senado).
- Un documento = todo lo que dijo un congresista en el año.
- DTM de 529 congresistas $\times$ 1.000 frases, ya limpias:
  - bigramas y trigramas, sin palabras vacías, con raíces (Porter): *illegal.alien*, *black.caucu*.
- Variable a predecir: `repshare`, el voto por Bush en 2004 en el distrito (o estado) del congresista.

Gentzkow y Shapiro (2010)

Las palabras predicen el voto?

- Todos los discursos del 109.º Congreso de EE. UU. en 2005 (Cámara y Senado).
- Un documento = todo lo que dijo un congresista en el año.
- DTM de 529 congresistas $\times$ 1.000 frases, ya limpias:
  - bigramas y trigramas, sin palabras vacías, con raíces (Porter): *illegal.alien*, *black.caucu*.
- Variable a predecir: `repshare`, el voto por Bush en 2004 en el distrito (o estado) del congresista.
- ¿podemos predecir qué tan republicano es el electorado de alguien sólo por cómo habla?

Gentzkow y Shapiro (2010)

Las palabras predicen el voto?

	Quién es	Partido	Voto Bush	*death tax*	*estate tax*
Tom Price	Repr., Georgia	R	70%	28	0
William Jefferson	Repr., Nueva Orleans	D	24%	2	32

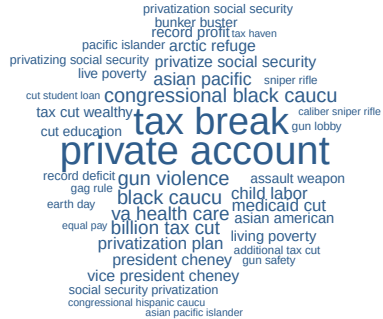
Gentzkow y Shapiro (2010)

Las palabras predicen el voto?

Republicanos



Demócratas



Gentzkow y Shapiro (2010)

El modelo

$$\text{repshare}_i = x_i'\beta + u_i$$

$$x_{ij} = 1\{\text{el congresista } i \text{ usó la frase } j\}$$

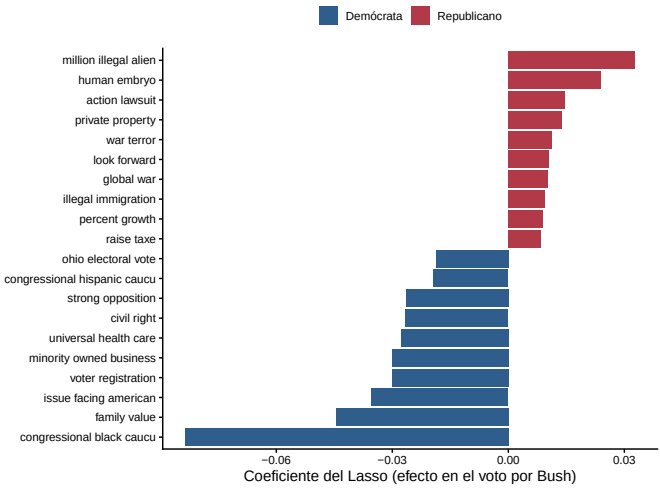
- 1.000 frases para 529 congresistas: $p > n$, MCO no funciona.
- Lasso:

$$\min_{\beta} \sum_i (\text{repshare}_i - x_i'\beta)^2 + \lambda \sum_j |\beta_j|$$

- λ por validación cruzada: quedan 71 de 1.000 frases.

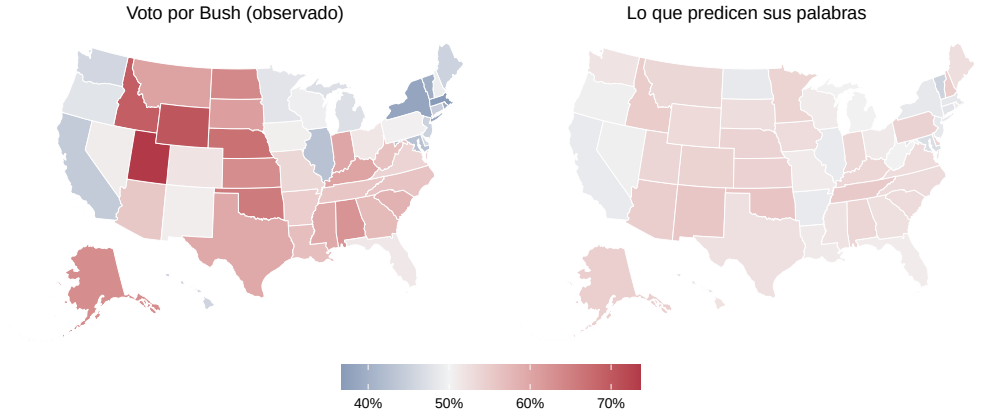
Gentzkow y Shapiro (2010)

Las frases más predictivas



Gentzkow y Shapiro (2010)

Predicciones



Gentzkow y Shapiro (2010)

Lo que encuentran

- Con las frases del Congreso miden el sesgo de 433 periódicos: qué tan "republicano" es su lenguaje.
- Estiman la demanda por periódicos según la ideología de los lectores.

Gentzkow y Shapiro (2010)

Lo que encuentran

- Con las frases del Congreso miden el sesgo de 433 periódicos: qué tan "republicano" es su lenguaje.
- Estiman la demanda por periódicos según la ideología de los lectores.
- Resultados:
  - Los lectores prefieren noticias afines a sus ideas.
  - Los periódicos responden: la demanda explica $\sim$20% de la variación del sesgo.
  - La identidad del dueño explica mucho menos.

BOW: resumen

- **Fortalezas**
  - Simple, rápida y muchas veces un buen punto de partida.
  - Captura temas a través de qué palabras se usan y cuánto.
- **Límites**
  - Ignora el contexto: *banco* (de peces o central).
  - Ignora el orden: “la inflación sube y el empleo baja” = “el empleo sube y la inflación baja”.
  - Ignora la negación: “no hubo crecimiento”
  - Alta dimensión y casi todo ceros.

Next

- Miércoles (Laboratorio 11): sobre los resúmenes de la Revista CEPAL (1980–2026).
- Traer instalados: `tidytext`, `stopwords`, `SnowballC`, `widyr`, `ggraph`, `tm`